

선형대수학팀

3팀
이재현
김규범
김민지
이정우
조혜현

INDEX

1. 선형대수의 기하학적 접근
2. 기하학적 접근의 응용
3. 행렬의 분해/인수화
4. 응용편

노름의 공식



$$L_p = \sqrt[p]{|x_1|^p + |x_2|^p + \cdots + |x_n|^p}$$

p 는 노름의 차수

ex. p 가 1이면 L1 Norm, p 가 2이면 L2 Norm

내적(Inner Products)

내적(Inner Products)

각 성분끼리의 곱의 합

$x = (x_1, x_2, \dots, x_n), y = (y_1, y_2, \dots, y_n)$ 일 때,

$$x \bullet y = x_1 y_1 + x_2 y_2 + \dots + x_n y_n$$

직교성(Orthogonality)

직교(Orthogonal)

두 벡터 사이의 각도가 **90°(직각)**

$$\cos\theta = \frac{x \cdot y}{\|x\|\|y\|} \text{에서 } \theta = 90^\circ \text{이면}$$

$$"x \cdot y = 0"$$

직교성(Orthogonality)

직교행렬(Orthogonal Matrix)

" $AA^T = A^T A = I$ ", " $A^T = A^{-1}$ "를 만족하는 정사각행렬
열벡터들이 **정규직교**



직교행렬을 이용한 선형 변환은
input vector x 의 크기가 변하지 않음

집합의 직교성



두 벡터의 직교성을 집합에 일반화

즉, 벡터들의 집합 $\{x_1, x_2, \dots, x_n\}$ 에서 각 x_i 가 서로 직교하는 집합

직교집합(Orthogonal Set)

$$x_i \cdot x_j = 0, \\ \text{where } i \neq j$$


정규직교집합(Orthonormal Set)

$$x_i \cdot x_j = 0, \text{ where } i \neq j \\ \& \\ \|x_i\| = 1$$


직교여공간(Orthogonal complement)

직교여공간(Orthogonal Complement)

집합 S 가 공집합이 아닌 R^n 에
속하는 벡터의 집합일 때,
 S 에 속하는 **모든 벡터들에**
직교하는 벡터들의 집합



정사영




$$Proj_b(a) \text{의 크기} = \|a\| \cos \theta = \|a\| \frac{\vec{a} \cdot \vec{b}}{\|\vec{a}\| \|\vec{b}\|} = \frac{\vec{a} \cdot \vec{b}}{\|\vec{b}\|}$$

$$Proj_b(a) \text{의 방향} = \frac{\vec{b}}{\|\vec{b}\|}$$

$$Proj_b(a) = \text{크기} \cdot \text{방향} = \frac{\vec{a} \cdot \vec{b}}{\|\vec{b}\|^2} \vec{b}$$

행렬식(Determinant)



행렬식

- 정사각행렬이 실수에 대응되는 함수
행렬 A 에 대해 $\det(A)$ 로 나타냄
- $\det(A) = 0 \leftrightarrow A$ 의 역행렬이 존재하지 않음
- $A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$ 일 때, $\det(A) = ad - bc$

행렬식 및 대각합

대각합(Trace)

- $A \in \mathbb{R}^{n \times n}$ 에 대해 $\text{tr}(A) = \sum_{i=1}^n a_{ii}$
- 정사각행렬 A의 대각합(trace)은 **대각성분의 합**

정사각행렬 $A = \begin{bmatrix} 1 & 3 & 2 \\ 2 & 7 & 4 \\ 1 & 5 & 2 \end{bmatrix}$ 일 때 $\text{tr}(A) = 1 + 7 + 2 = 10$

고유값과 고유벡터

고유값과 고유벡터

$A \in \mathbb{R}^{n \times n}$ 에 대해 영벡터를 제외한 $x \in \mathbb{R}^n$ 에서
 $Ax = \lambda x$ 일 때, λ 를 고유값, x 를 고유벡터라고 함

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \quad n \times n \text{ 정사각행렬}$$

$$\overset{\text{고유벡터 } (\neq \vec{0})}{A} \overset{\text{고유값}}{X} = \overset{\text{고유값}}{\lambda} \overset{\text{고유값}}{X}$$

$$Ax = \lambda x = \lambda Ix$$

$$Ax - \lambda Ix = 0$$

$$(A - \lambda I)x = 0$$



$Ax = \lambda x$ 에서
고유벡터 x 가 존재하기 위한 조건?
 고유값과 고유벡터

$(A - \lambda I)x = 0$ 에서 영벡터가 아닌 x 가 존재해야 함

만약 $(A - \lambda I)$ 의 역행렬이 존재한다면

$x = (A - \lambda I)^{-1}0$ 이 되므로 x 는 영벡터가 되어

고유벡터라고 할 수 없음

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}$$

$$Ax = \lambda x = \lambda Ix$$

$$Ax - \lambda Ix = 0$$

이는 $\det(A - \lambda I) = 0$ 를 만족해야 함을 의미

양확정행렬 (Positive definite matrix)


양확정행렬

“양수를 확실히 만드는 행렬”에서 유래

$A \in \mathbb{R}^{n \times n}$, 영벡터를 제외한 임의의 $x \in \mathbb{R}^n$, $x^T A x > 0$

Example

$$A = \begin{bmatrix} 2 & 6 \\ 6 & 20 \end{bmatrix}$$



$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$ 로 표기하면,

$$x^T A x = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 6 \\ 6 & 20 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 2x_1^2 + 12x_1x_2 + 20x_2^2$$

$$\text{이 때, } 2x_1^2 + 12x_1x_2 + 20x_2^2 = 2(x_1 + 3x_2)^2 + 2x_2^2 > 0$$

따라서 A는 양확정행렬

출레스키분해(Cholesky Decomposition)

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} = \begin{bmatrix} l_{11} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ l_{n1} & \cdots & l_{nn} \end{bmatrix} \begin{bmatrix} l_{11} & \cdots & l_{1n} \\ \vdots & \ddots & \vdots \\ 0 & \cdots & l_{nn} \end{bmatrix}$$

A
 L
 L^T

대칭 & 양확정 행렬인 행렬 A에 대해 다음이 성립


- 1) 0이 아닌 성분이 양수로 구성된 **하삼각 행렬 L**에 대해 $A = LL^T$ 을 만족
- 2) 이때 L은 행렬 A에 대해 유일하게 존재하며 출레스키 팩터라고 정의

출레스키 분해  **행렬식 계산을 간단화**

대각행렬이란?

대각행렬(Diagonal Matrix)

대각선에만 0이 아닌 성분이 있고,
그 외의 성분은 모두 0인 행렬


$$D = \begin{pmatrix} C_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & C_n \end{pmatrix}$$

대각행렬은 행렬식, 거듭제곱, 역행렬 계산 등에서 굉장한 이점을 지님.

고유값 분해란?

고유값 분해(EigenDecomposition; EVD)


어떤 정사각행렬 $D \in \mathbb{R}^{n \times n}$ 에 대해
A의 고유벡터들이 \mathbb{R}^n 의 기저를 형성할 때,

$$A = PDP^{-1} \text{만들 수 있음}$$

↓

$$P \in \mathbb{R}^{n \times n} \text{이며,}$$

D는 각 대각 성분이 A의 고유값으로 구성된 대각행렬

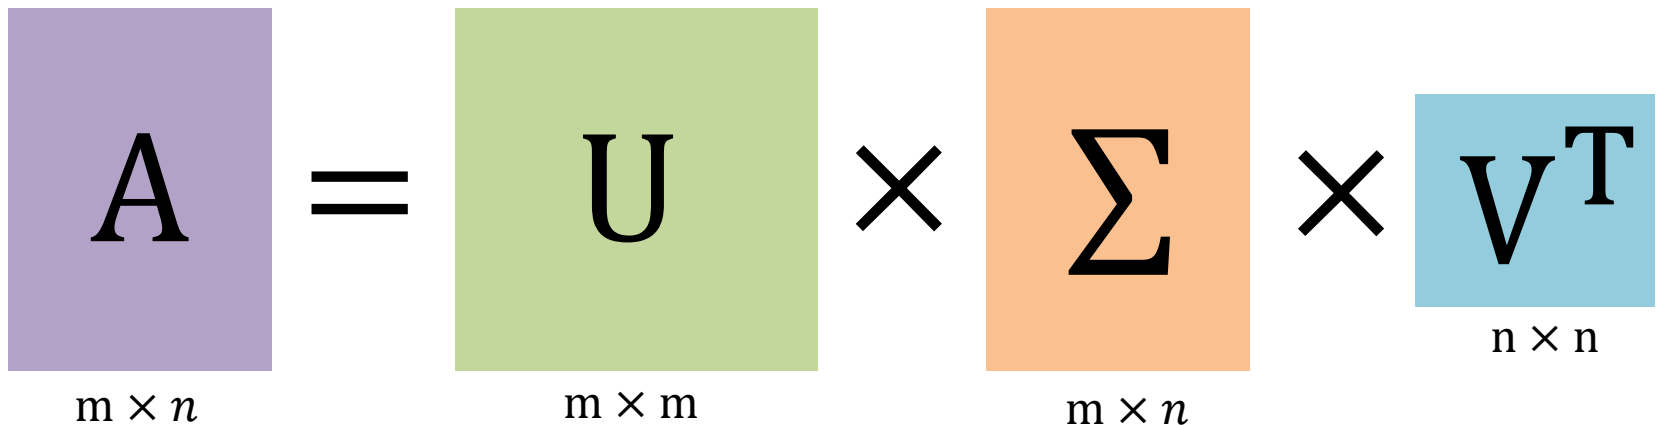


위의 과정을 고유값 분해라고 부름

특이값 분해의 개념

특이값 분해


- $A : m \times n$ 행렬이며 계수(rank)가 $0 \leq \text{rank}(A) \leq \min(m, n)$
 - $V^T : n \times n$ 행렬, $U : m \times m$ 행렬, $\Sigma : m \times n$ 행렬
- U 와 V 는 직교행렬이며 Σ 는 성분이 $\Sigma_{ii} \neq 0, \Sigma_{ij} = 0 (i \neq j)$ 인 행렬



The diagram illustrates the Singular Value Decomposition (SVD) of a matrix A . It shows the equation $A = U \Sigma V^T$ where each matrix is represented by a colored square. Below each square is its dimension: A is $m \times n$ (purple square), U is $m \times m$ (green square), Σ is $m \times n$ (orange square), and V^T is $n \times n$ (blue square). The matrix V^T is shown as a square, indicating it is $n \times n$.

$$\begin{matrix} \text{m} \times \text{n} \\ A \\ \text{m} \times \text{m} \\ U \\ \text{m} \times \text{n} \\ \Sigma \\ \text{n} \times \text{n} \\ V^T \end{matrix} = U \Sigma V^T$$

특이값 분해의 기하학적 해석



- V^T : Domain(정의역)에서 표준 기저에서 다른 기저로 변환 (Basis Change)
- Σ : 새로운 기저에서 값 스케일링
- U : 회전(Rotation)을 통해 Codomain(공역)에서 기저 변환

Reduced SVD

Reduced SVD의 종류들

$$\begin{array}{c} (m \times s) \\ \boxed{A} \end{array} = \begin{array}{c} (m \times m) \\ \boxed{U} \end{array} \begin{array}{c} (m \times s) \\ \begin{array}{c} \sigma_1 \backslash \\ \sigma_s \\ 0 \end{array} \end{array} \begin{array}{c} (s \times s) \\ \boxed{V^T} \end{array}$$

<그림 2> full SVD

$$\begin{array}{c} \boxed{A} \end{array} = \begin{array}{c} (m \times s) \\ \boxed{U_s} \end{array} \begin{array}{c} (s \times s) \\ \begin{array}{c} \sigma_1 \backslash \\ \sigma_s \end{array} \end{array} \begin{array}{c} (s \times s) \\ \boxed{V^T} \end{array}$$

<그림 3> thin SVD

$$\begin{array}{c} \boxed{A} \end{array} = \begin{array}{c} (m \times r) \\ \boxed{U_r} \end{array} \begin{array}{c} (r \times r) \\ \begin{array}{c} \sigma_1 \backslash \\ \sigma_r \end{array} \end{array} \begin{array}{c} (r \times r) \\ \boxed{V_r^T} \end{array}$$

r : 0이 아닌 값들의 개수
<그림 4> Compact SVD

$$\begin{array}{c} \boxed{A'} \end{array} = \begin{array}{c} (m \times t) \\ \boxed{U_t} \end{array} \begin{array}{c} (t \times t) \\ \begin{array}{c} \sigma_1 \backslash \\ \sigma_t \end{array} \end{array} \begin{array}{c} (t \times t) \\ \boxed{V_t^T} \end{array}$$

t : r 보다도 더 작은 수(원본 복구 불가능)
<그림 5> Truncated SVD